



Universidad Técnica Federico Santa María

Casa Central

Informe N°1

Analítica para Negocios ICS40125

Presentantes:

Angello Avellaneda, Vicente Yañez, Francisco Cariga,

Alvaro Vergara, Sebastian Rodriguez

Asignatura:

Analítica para Negocios

Profesor de la asignatura:

Francisco Alfaro

Fecha de Entrega 1er avance:

08 de Junio, 2026

1.Introducción

El presente informe corresponde al primer avance del proyecto de la asignatura Analítica para Negocios (ICS40125), desarrollado sobre un dataset de compensaciones de empleados de TalentCo, una firma multinacional de consultoría.

El objetivo central del proyecto es identificar los factores que determinan el salario de los empleados y construir un modelo predictivo de regresión lineal que permita estimar la compensación anual en función de variables individuales y organizacionales.

El análisis se estructura en cuatro etapas: exploración y limpieza de datos, pruebas de hipótesis, construcción del modelo de regresión y refinamiento del mismo. Los resultados se sintetizan finalmente en un informe ejecutivo dirigido a la Dirección de Recursos Humanos de TalentCo.

2. Análisis Exploratorio de Datos

Carga e Inspección Inicial del Dataset

El análisis se inició cargando el conjunto de datos `employee_compensation.csv` directamente desde el repositorio del curso mediante la librería `pandas`. El dataset contiene registros de ~10.100 registros, en donde tras la limpieza nos quedan 9.216 empleados distribuidos en distintos departamentos, regiones y niveles de cargo de la empresa TalentCo, una firma multinacional de consultoría.

La inspección inicial permitió identificar la estructura del dataset: 9 variables en total, compuestas por 4 variables numéricas (`Salary`, `Years_Experience`, `Age`, `Performance_Score`) y 5 variables categóricas (`Education_Level`, `Department`, `Region`, `Job_Level` y `Gender`). La variable objetivo del proyecto es `Salary`, que representa el salario bruto anual en dólares.

Al visualizar las primeras 10 filas del `DataFrame` se detectaron de inmediato tres problemas relevantes: (1) presencia de valores nulos en las columnas `Salary` y `Performance_Score`, (2) inconsistencias en las variables categóricas, como entradas en mayúsculas irregulares (por ejemplo, 'bachelor' junto a 'Bachelor', o 'FINANCE' junto a 'Finance'), y (3) valores de `Performance_Score` fuera del rango declarado (1.0–5.0), con registros que alcanzan valores negativos. Estas observaciones guiaron directamente el proceso de limpieza posterior.

Proceso de Limpieza y Tratamiento de Datos

La limpieza de datos constituyó una etapa fundamental antes de cualquier análisis. Se aplicaron las siguientes decisiones de manera secuencial:

Eliminación de registros con nulos críticos: las filas con valores faltantes en `Salary` o `Performance_Score` fueron eliminadas con `dropna()`, ya que ambas variables son esenciales para el objetivo del proyecto. Dado que el porcentaje de registros afectados era reducido, esta estrategia no comprometió la representatividad del dataset.

Imputación de variables categóricas: para las columnas `Education_Level`, `Gender`, `Department` y `Region`, los valores nulos restantes fueron reemplazados con la moda (valor más frecuente) de cada columna. Esto se realizó de forma programática iterando sobre la lista de columnas categóricas para evitar sesgos arbitrarios.

Normalización de strings: se aplicó `.str.strip().str.title()` a todas las variables categóricas para eliminar espacios en blanco y uniformizar el formato de texto. Esta corrección fue necesaria para que el conteo de categorías fuera coherente y no generara grupos duplicados por diferencias de capitalización.

Imputación de variables numéricas: para `Years_Experience` y `Age`, los valores faltantes fueron reemplazados con la mediana de cada columna, criterio más robusto que la media ante la posible presencia de valores extremos.

Corrección de valores atípicos (outliers): se aplicó recorte mediante `.clip()` para `Years_Experience` (rango: 0–50 años) y `Age` (rango: 18–65 años), que corresponden a límites lógicos dentro del contexto laboral. Se cuantificaron los registros corregidos para tener trazabilidad del proceso: 26 valores ajustados en `Years_Experience` y 37 en `Age`. Adicionalmente, se detectaron y eliminaron 97 registros duplicados exactos" (los outliers 26 y 37 se mantienen).

Como resultado de este proceso, el dataset quedó listo para el análisis con 9.216 registros, sin valores nulos y con variables categóricas homogéneas.

Estadísticas Descriptivas y Visualizaciones

Una vez limpio el dataset, se calcularon estadísticas descriptivas (media, mediana, desviación estándar, mínimo y máximo) para todas las variables numéricas. El salario promedio resultó en \$95.768 USD anuales, con una mediana de \$91.726 USD, lo que anticipa la asimetría positiva observada posteriormente en el histograma.

Se generaron tres visualizaciones clave mediante matplotlib y seaborn:

- **Histograma del salario con curva de densidad KDE:** se observó una distribución con asimetría positiva marcada, con cola derecha extendida hacia valores cercanos a \$400.000 USD. La media (\$95.730) supera a la mediana (\$91.702), confirmando el sesgo. Los valores extremos corresponden a empleados Senior en departamentos de alta demanda.
- **Boxenplot del salario por nivel de cargo:** esta visualización mostró una separación salarial clara entre los niveles Junior, Mid y Senior, siendo esta diferencia la más marcada del dataset. Si bien existe cierto solapamiento en los extremos de cada distribución, los rangos centrales de cada nivel son notoriamente distintos, anticipando que Job_Level será un predictor clave en el modelo.
- **Diagrama de dispersión con línea de regresión entre Years_Experience y Salary:** se evidenció una tendencia positiva clara, con alta dispersión vertical especialmente en los primeros años de experiencia. Esta relación fue confirmada formalmente en la Parte 2.

Se complementó el análisis con un mapa de calor de correlaciones entre las variables numéricas, aplicando una máscara triangular para evitar redundancia visual. El heatmap confirmó que Years_Experience es la variable con mayor correlación lineal con Salary ($r = 0.59$), mientras que Age y Years_Experience presentan una correlación de 0.72 entre sí, confirmando el riesgo de multicolinealidad anticipado y posteriormente diagnosticado mediante el VIF en la Parte 4.

3. Pruebas de hipótesis

Planteamiento y Metodología

La Parte 2 buscó responder formalmente la pregunta de negocio central: ¿los años de experiencia determinan de manera significativa las diferencias salariales? Para ello se aplicaron dos enfoques estadísticos complementarios con un nivel de significancia del 5% ($\alpha = 0,05$).

Las hipótesis planteadas fueron las siguientes:

- H_0 : Los años de experiencia no tienen relación lineal con el salario ($\rho = 0$).
- H_1 : Los años de experiencia están positivamente asociados con el salario ($\rho > 0$).

Correlación de Pearson y Prueba t

Se utilizó la función `stats.pearsonr()` de la librería `scipy` para calcular el coeficiente de correlación de Pearson entre `Years_Experience` y `Salary`, junto con su p-valor asociado. Los resultados arrojaron un coeficiente de $r = 0,5902$ con p-valor prácticamente igual a cero, por lo que se rechazó la hipótesis nula. Esto confirma que existe una asociación lineal positiva entre la experiencia y el salario: a medida que los empleados acumulan más años de trayectoria, su compensación anual tiende a ser mayor.

Este hallazgo es consistente con lo observado visualmente en el diagrama de dispersión de la Parte 1, donde la línea de regresión mostró una pendiente positiva evidente a lo largo de todo el rango de experiencia.

Prueba Bonus: Junior vs. Senior

Como análisis adicional, se evaluó si existe una diferencia salarial estadísticamente significativa entre empleados de nivel Junior y Senior mediante una prueba t de Welch para dos muestras independientes (que no asume igualdad de varianzas). Esta prueba es apropiada dado que ambos grupos tienen tamaños de muestra distintos y varianzas heterogéneas.

El estadístico t resultó muy elevado en valor absoluto ($t = -79,73$), con un p-valor prácticamente igual a cero. Las medias salariales de cada grupo reflejan la magnitud de esta diferencia: los empleados Junior perciben en promedio \$74.847 USD anuales, mientras que los Senior alcanzan \$126.935 USD, una brecha de aproximadamente \$52.088 USD. Este resultado llevó a rechazar H_0 : la diferencia salarial entre ambos niveles de cargo no es atribuible al azar, sino que refleja una estructura real de compensaciones en TalentCo. Este hallazgo refuerza la intuición de que `Job_Level` será el predictor más poderoso del modelo de regresión.

4. Regresión Lineal con variables categóricas

Justificación Previa de Variables (Paso 1)

Antes de construir el modelo, se realizó una reflexión teórica y de negocio sobre las variables a incluir. Este ejercicio fue fundamental para articular hipótesis previas y compararlas luego con los coeficientes del modelo.

Se identificaron como predictores más fuertes esperados:

- **Job_Level:** es el predictor más fuerte anticipado. La prueba t confirmó diferencias salariales de \$52.088 USD entre Junior y Senior ($t = -79,73$). Las bandas salariales en las empresas se estructuran principalmente en torno al nivel de cargo.
- **Years_Experience:** correlación de Pearson $r = 0,59$ con el salario, la más alta entre las variables numéricas. A mayor experiencia, mayor productividad esperada.
- **Department:** distintas áreas tienen mercados laborales y bandas salariales sistemáticamente diferentes.

Respecto a variables que se incluirían aun siendo estadísticamente poco significativas, se argumentó mantener Gender para detectar posibles brechas salariales de equidad, y Region, dado que los costos de vida y los mercados laborales varían geográficamente. Esta decisión quedó validada por los resultados del modelo: Gender_Male resultó estadísticamente significativo ($p = 0,008$), confirmando la existencia de una brecha salarial por género en TalentCo.

Finalmente, se anticipó que Age y Years_Experience estarían fuertemente correlacionadas entre sí, así como Job_Level y Years_Experience. Esto fue identificado como un riesgo potencial para la estabilidad de los coeficientes individuales, posteriormente confirmado en la Parte 4 mediante el VIF moderado (Job_Level $\approx 5,5$; Years_Experience $\approx 3,6$; Age $\approx 3,1$), sin alcanzar niveles severos.

Preparación de los Datos (Paso 2)

Para incorporar las variables categóricas al modelo fue necesario transformarlas en representaciones numéricas. Se aplicaron dos técnicas según la naturaleza de cada variable:

Label Encoding para Job_Level: dado que esta variable es ordinal (Junior < Mid < Senior), se asignaron los valores enteros 0, 1 y 2 respectivamente mediante un diccionario de mapeo explícito. Esta codificación preserva la jerarquía natural de los niveles de cargo.

One-Hot Encoding para las variables nominales: para Education_Level, Department, Region y Gender, se aplicó `pd.get_dummies()` con el parámetro `drop_first=True`. Este parámetro elimina la primera categoría de cada grupo como categoría de referencia, evitando la trampa de la variable ficticia (multicolinealidad perfecta), condición necesaria para que el modelo OLS sea identificable.

Como resultado de este proceso, el dataset pasó de 9 columnas originales a 14 variables predictoras. Se detectaron además dos columnas residuales del proceso de codificación donde los strings 'nan' presentes en Gender y Region se convirtieron a valores nulos reales antes de imputar, evitando categorías ficticias residuales.

Construcción del Modelo (Paso 3)

Los datos codificados fueron divididos en conjunto de entrenamiento (80%) y de prueba (20%) mediante `train_test_split` con `random_state=42`, garantizando reproducibilidad. Antes de la división, se eliminaron filas con valores infinitos o nulos residuales para asegurar la estabilidad numérica del ajuste.

Se construyeron dos modelos de regresión lineal con todas las variables disponibles:

- **Regresión OLS con statsmodels:** permite obtener el resumen estadístico completo del modelo, incluyendo coeficientes, errores estándar, estadísticos t y p-valores para cada predictor, así como métricas globales como el R^2 y el R^2 ajustado. Se añadió una constante mediante `sm.add_constant()` antes del ajuste.
- **Regresión lineal con scikit-learn:** orientada principalmente a la predicción, permite calcular métricas de desempeño (MAE, MAPE, RMSE, R^2) tanto en entrenamiento como en prueba de manera directa.

Ambos modelos utilizaron exactamente las mismas variables y división de datos, produciendo predicciones idénticas, lo que verificó la consistencia entre implementaciones.

Evaluación del Modelo (Paso 4)

Se definió una función de evaluación que calcula de forma consistente las cinco métricas requeridas: MAE, MAPE, RMSE, R^2 y R^2 ajustado, tanto para entrenamiento como para prueba en ambos modelos.

Los resultados del modelo completo arrojaron un R^2 de 0,506 en entrenamiento y 0,615 en prueba, con un MAE de \$6.389 USD y MAPE de 9,12% en el conjunto de prueba. La diferencia entre ambos conjuntos no indica sobreajuste, sino que refleja la variabilidad propia de la partición aleatoria. El summary OLS reportó además un condition number de $\approx 2,5 \times 10^2$ (253), señal consistente con la multicolinealidad diagnosticada posteriormente mediante el VIF.

5. Análisis y Refinamiento del Modelo

Interpretación de P-valores (Paso 1)

A partir del resumen OLS del modelo completo, se ordenaron las variables según su p-valor para identificar aquellas estadísticamente insignificantes. Se detectó una sola variable con $p > 0,05$: `Region_West` ($p \approx 0,058$).

`Region_West`, en cambio, fue conservada: su insignificancia estadística puede deberse a que la variabilidad salarial de esa región ya está parcialmente capturada por otras variables del modelo, y su exclusión podría sesgar las predicciones para empleados ubicados en esa zona geográfica.

El modelo final conserva las 14 variables; al evaluar una alternativa sin `Region_West` las métricas fueron prácticamente idénticas ($R^2 \approx 0,615$ en prueba, $MAE \approx \$6.389$), por lo que se conservó.

Análisis de Multicolinealidad — VIF (Paso 2)

Se calculó el Factor de Inflación de Varianza (VIF) para todas las variables del modelo refinado. Los resultados confirmaron la multicolinealidad anticipada en el Paso 1 de la Parte 3:

- **Age** $\approx 3,1$ — multicolinealidad moderada
- **Job_Level** $\approx 5,5$ — multicolinealidad moderada-alta
- **Years_Experience** $\approx 3,6$ — multicolinealidad moderada-alta
- **Resto de variables:** $VIF < 2$ — multicolinealidad moderada, ninguna severa.

La correlación de 0,72 entre `Age` y `Years_Experience` se traduce en un VIF moderado (~ 3), que no compromete el modelo, `Age` representa la edad biológica del empleado, mientras que `Years_Experience` mide la trayectoria profesional acumulada. Un empleado puede tener mucha edad y poca experiencia, o viceversa. Se reconoce como limitación que los errores estándar de estos coeficientes están inflados, lo que dificulta su interpretación individual pero no invalida el poder predictivo global del modelo.

Verificación de Supuestos de Regresión (Paso 3)

Se verificaron los dos supuestos principales de la regresión lineal sobre el modelo refinado:

Normalidad de residuos: el histograma de residuos muestra una distribución muy concentrada en torno a cero con cola derecha extendida, y el gráfico Q-Q evidencia desviación significativa en ambas colas. Se concluye que los residuos no siguen una distribución normal estricta. Esta desviación es esperable en datos salariales reales, donde la presencia de sueldos muy altos genera asimetría estructural. Para el objetivo predictivo del proyecto esta limitación es aceptable, aunque implica que los intervalos de confianza de los coeficientes deben interpretarse con cautela.

Homocedasticidad: la prueba de Breusch-Pagan arrojó un estadístico $LM = 10,34$ con p-valor = 0,737, por lo que no se rechaza H_0 . La varianza de los errores es razonablemente constante a lo

largo de los valores predichos, lo que constituye una condición favorable para la validez de las inferencias del modelo.

6. Informe ejecutivo, determinantes salariales en TalentCo

Para: Dirección de Recursos Humanos de TalentCo

Tras analizar los registros de compensación de más de 9.200 empleados, presentamos los principales hallazgos sobre cómo se determinan los salarios en TalentCo y recomendaciones para fortalecer la equidad y la transparencia de su política de compensaciones.

Principales determinantes del salario. El factor que más influye en la compensación es el nivel de cargo (Junior, Mid, Senior), seguido por el departamento y el nivel educacional. La experiencia profesional y el desempeño también aportan, aunque en menor magnitud. En conjunto, estos factores explican una parte sustancial de las diferencias salariales, lo que indica que la estructura responde mayoritariamente a criterios objetivos y razonables.

Impacto de la experiencia. Cada año adicional de experiencia profesional se asocia, en promedio, con un incremento cercano a \$830 USD anuales, manteniendo el resto de factores constante. Es un efecto real y consistente, aunque más moderado que el del nivel de cargo.

Diferencias por departamento y región. Existen brechas claras entre departamentos: Ingeniería es el área mejor remunerada, mientras que Recursos Humanos, Ventas y Marketing perciben en promedio entre 13.000 y 18.000 USD menos al año en perfiles equivalentes. Las diferencias por región son mucho menores (entre 2.000 y 3.000 USD), por lo que la geografía no parece ser una fuente importante de inequidad.

Ascenso de Mid a Senior. Según el modelo, promover a un empleado de nivel Mid a Senior se asocia con un aumento esperado de aproximadamente \$19.200 USD anuales, manteniendo todo lo demás constante. Esta cifra es útil para presupuestar promociones y comunicar trayectorias de carrera.

Recomendaciones.

Revisar las brechas entre departamentos para confirmar que reflejan diferencias reales de mercado y no inequidades internas.

Auditar la diferencia salarial por género detectada (los hombres perciben en promedio unos \$1.370 USD más que las mujeres en perfiles comparables): aunque modesta, es estadísticamente real y merece seguimiento.

Formalizar bandas salariales por nivel y experiencia para dar previsibilidad.

Publicar criterios de promoción claros para reforzar la percepción de justicia.

En síntesis, la compensación en TalentCo está mayormente bien estructurada, pero existen oportunidades concretas para mejorar la equidad de género y la transparencia entre departamentos.

7. Conclusión

El presente análisis permitió caracterizar con solidez la estructura salarial de TalentCo a partir de sus registros de compensación. A lo largo de las cuatro etapas del proyecto se obtuvieron hallazgos consistentes entre sí: el nivel de cargo es el principal determinante del salario, seguido por los años de experiencia, el departamento y el nivel educacional. La prueba t confirmó diferencias estadísticamente significativas entre niveles Junior y Senior, y el modelo de regresión lineal logró capturar una parte sustancial de la variabilidad salarial con un R^2 de 0,615 en el conjunto de prueba.

Se identificaron además limitaciones relevantes: los residuos presentan asimetría positiva propia de datos salariales, y existe multicolinealidad moderada entre Age y Years_Experience, lo que infla los errores estándar de esos coeficientes sin comprometer el poder predictivo global del modelo.

Como trabajo futuro se recomienda explorar transformaciones de la variable objetivo (por ejemplo, logaritmo del salario) para mejorar la normalidad de los residuos, así como evaluar modelos no lineales que puedan capturar interacciones entre variables y elevar el desempeño predictivo.

8. Anexo

El código completo del análisis, incluyendo la limpieza de datos, visualizaciones, pruebas de hipótesis y construcción del modelo, se encuentra disponible en el siguiente enlace:

<https://colab.research.google.com/drive/1WXFib-IMkneP18JXx4E8OjR5fkznhSkP#scrollTo=918f6c7a>