Universidad Técnica Federico Santa María

Casa Central

Informe N°1
Analítica para Negocios ICS40125

Presentantes:

Angello Avellaneda, Vicente Yañez, Francisco Cariga,

Alvaro Vergara, Sebastian Rodriguez

Asignatura:

Analítica para Negocios

Profesor de la asignatura:

Francisco Alfaro

Fecha de Entrega 1er avance:

15 de Mayo, 2026

1.Análisis Exploratorio de Datos

Carga e Inspección Inicial del Dataset

El análisis se inició cargando el conjunto de datos employee_compensation.csv directamente desde el repositorio del curso mediante la librería pandas. El dataset contiene registros de 9.307 empleados distribuidos en distintos departamentos, regiones y niveles de cargo de la empresa TalentCo, una firma multinacional de consultoría.

La inspección inicial permitió identificar la estructura del dataset: 9 variables en total, compuestas por 4 variables numéricas (Salary, Years_Experience, Age, Performance_Score) y 5 variables categóricas (Education_Level, Department, Region, Job_Level y Gender). La variable objetivo del proyecto es Salary, que representa el salario bruto anual en dólares.

Al visualizar las primeras 10 filas del DataFrame se detectaron de inmediato tres problemas relevantes: (1) presencia de valores nulos en las columnas Salary y Performance_Score, (2) inconsistencias en las variables categóricas, como entradas en mayúsculas irregulares (por ejemplo, 'bachelor' junto a 'Bachelor', o 'FINANCE' junto a 'Finance'), y (3) valores de Performance_Score fuera del rango declarado (1.0–5.0), con registros que alcanzan valores negativos. Estas observaciones guiaron directamente el proceso de limpieza posterior.

Proceso de Limpieza y Tratamiento de Datos

La limpieza de datos constituyó una etapa fundamental antes de cualquier análisis. Se aplicaron las siguientes decisiones de manera secuencial:

Eliminación de registros con nulos críticos: las filas con valores faltantes en Salary o Performance_Score fueron eliminadas con dropna(), ya que ambas variables son esenciales para el objetivo del proyecto. Dado que el porcentaje de registros afectados era reducido, esta estrategia no comprometió la representatividad del dataset.

Imputación de variables categóricas: para las columnas Education_Level, Gender, Department y Region, los valores nulos restantes fueron reemplazados con la moda (valor más frecuente) de cada columna. Esto se realizó de forma programática iterando sobre la lista de columnas categóricas para evitar sesgos arbitrarios.

Normalización de strings: se aplicó .str.strip().str.title() a todas las variables categóricas para eliminar espacios en blanco y uniformizar el formato de texto. Esta corrección fue necesaria para que el conteo de categorías fuera coherente y no generara grupos duplicados por diferencias de capitalización.

Imputación de variables numéricas: para Years_Experience y Age, los valores faltantes fueron reemplazados con la mediana de cada columna, criterio más robusto que la media ante la posible presencia de valores extremos.

Corrección de valores atípicos (outliers): se aplicó recorte mediante .clip() para Years_Experience (rango: 0–50 años) y Age (rango: 18–65 años), que corresponden a límites lógicos dentro del contexto laboral. Se cuantificaron los registros corregidos para tener trazabilidad del proceso: 26 valores ajustados en Years_Experience y 37 en Age. Adicionalmente, se detectaron 97 registros duplicados en el dataset, los cuales fueron reportados en la inspección inicial.

Como resultado de este proceso, el dataset quedó listo para el análisis con 9.307 registros, sin valores nulos y con variables categóricas homogéneas.

Estadísticas Descriptivas y Visualizaciones

Una vez limpio el dataset, se calcularon estadísticas descriptivas (media, mediana, desviación estándar, mínimo y máximo) para todas las variables numéricas. El salario promedio resultó en $95.730 USD anuales, con una mediana de $91.702 USD, lo que anticipa la asimetría positiva observada posteriormente en el histograma.

Se generaron tres visualizaciones clave mediante matplotlib y seaborn:

- **Histograma del salario con curva de densidad KDE**: se observó una distribución con asimetría positiva marcada, con cola derecha extendida hacia valores cercanos a $400.000 USD. La media ($95.730) supera a la mediana ($91.702), confirmando el sesgo. Los valores extremos corresponden a empleados Senior en departamentos de alta demanda.
- **Boxenplot del salario por nivel de cargo**: esta visualización mostró una separación salarial clara entre los niveles Junior, Mid y Senior, siendo esta diferencia la más marcada del dataset. Si bien existe cierto solapamiento en los extremos de cada distribución, los rangos centrales de cada nivel son notoriamente distintos, anticipando que Job_Level será un predictor clave en el modelo.
- **Diagrama de dispersión con línea de regresión entre Years_Experience y Salary**: se evidenció una tendencia positiva clara, con alta dispersión vertical especialmente en los primeros años de experiencia. Esta relación fue confirmada formalmente en la Parte 2.

Se complementó el análisis con un mapa de calor de correlaciones entre las variables numéricas, aplicando una máscara triangular para evitar redundancia visual. El heatmap confirmó que Years_Experience es la variable con mayor correlación lineal con Salary ($r = 0.59$), mientras que Age y Years_Experience presentan una correlación de 0.72 entre sí, confirmando el riesgo de multicolinealidad anticipado y posteriormente diagnosticado mediante el VIF en la Parte 4.

2. Pruebas de hipótesis

Planteamiento y Metodología

La Parte 2 buscó responder formalmente la pregunta de negocio central: ¿los años de experiencia determinan de manera significativa las diferencias salariales? Para ello se aplicaron dos enfoques estadísticos complementarios con un nivel de significancia del 5% ($\alpha = 0{,}05$).

Las hipótesis planteadas fueron las siguientes:

- H_0: Los años de experiencia no tienen relación lineal con el salario ($\rho = 0$).
- H_1: Los años de experiencia están positivamente asociados con el salario ($\rho > 0$).

Correlación de Pearson y Prueba t

Se utilizó la función stats.pearsonr() de la librería scipy para calcular el coeficiente de correlación de Pearson entre Years_Experience y Salary, junto con su p-valor asociado. Los resultados arrojaron un coeficiente de $r = 0{,}5919$ con p-valor prácticamente igual a cero, por lo que se rechazó la hipótesis nula.

Esto confirma que existe una asociación lineal positiva entre la experiencia y el salario: a medida que los empleados acumulan más años de trayectoria, su compensación anual tiende a ser mayor.

Este hallazgo es consistente con lo observado visualmente en el diagrama de dispersión de la Parte 1, donde la línea de regresión mostró una pendiente positiva evidente a lo largo de todo el rango de experiencia.

Prueba Bonus: Junior vs. Senior

Como análisis adicional, se evaluó si existe una diferencia salarial estadísticamente significativa entre empleados de nivel Junior y Senior mediante una prueba t de Welch para dos muestras independientes (que no asume igualdad de varianzas). Esta prueba es apropiada dado que ambos grupos tienen tamaños de muestra distintos y varianzas heterogéneas.

El estadístico t resultó muy elevado en valor absoluto ($t = -80{,}67$), con un p-valor prácticamente igual a cero. Las medias salariales de cada grupo reflejan la magnitud de esta diferencia: los empleados Junior perciben en promedio $74.807 USD anuales, mientras que los Senior alcanzan $127.052 USD, una brecha de aproximadamente $52.245 USD. Este resultado llevó a rechazar H_0: la diferencia salarial entre ambos niveles de cargo no es atribuible al azar, sino que refleja una estructura real de compensaciones en TalentCo. Este hallazgo refuerza la intuición de que Job_Level será el predictor más poderoso del modelo de regresión.

3. Regresión Lineal con variables categóricas

Justificación Previa de Variables (Paso 1)

Antes de construir el modelo, se realizó una reflexión teórica y de negocio sobre las variables a incluir. Este ejercicio fue fundamental para articular hipótesis previas y compararlas luego con los coeficientes del modelo.

Se identificaron como predictores más fuertes esperados:

- **Job_Level**: es el predictor más fuerte anticipado. La prueba t confirmó diferencias salariales de $52.245 USD entre Junior y Senior ($t = -80{,}67$). Las bandas salariales en las empresas se estructuran principalmente en torno al nivel de cargo.
- **Years_Experience**: correlación de Pearson $r = 0{,}59$ con el salario, la más alta entre las variables numéricas. A mayor experiencia, mayor productividad esperada.
- **Department**: distintas áreas tienen mercados laborales y bandas salariales sistemáticamente diferentes.

Respecto a variables que se incluirían aun siendo estadísticamente poco significativas, se argumentó mantener Gender para detectar posibles brechas salariales de equidad, y Region, dado que los costos de vida y los mercados laborales varían geográficamente. Esta decisión quedó

validada por los resultados del modelo: Gender_Male resultó estadísticamente significativo ($p = 0{,}004$), confirmando la existencia de una brecha salarial por género en TalentCo.

Finalmente, se anticipó que Age y Years_Experience estarían fuertemente correlacionadas entre sí, así como Job_Level y Years_Experience. Esto fue identificado como un riesgo potencial para la estabilidad de los coeficientes individuales, posteriormente confirmado en la Parte 4 mediante el VIF (Age: 15,58; Years_Experience: 9,71).

Preparación de los Datos (Paso 2)

Para incorporar las variables categóricas al modelo fue necesario transformarlas en representaciones numéricas. Se aplicaron dos técnicas según la naturaleza de cada variable:

Label Encoding para Job_Level: dado que esta variable es ordinal (Junior < Mid < Senior), se asignaron los valores enteros 0, 1 y 2 respectivamente mediante un diccionario de mapeo explícito. Esta codificación preserva la jerarquía natural de los niveles de cargo.

One-Hot Encoding para las variables nominales: para Education_Level, Department, Region y Gender, se aplicó pd.get_dummies() con el parámetro drop_first=True. Este parámetro elimina la primera categoría de cada grupo como categoría de referencia, evitando la trampa de la variable ficticia (multicolinealidad perfecta), condición necesaria para que el modelo OLS sea identificable.

Como resultado de este proceso, el dataset pasó de 9 columnas originales a 17 variables predictoras. Se detectaron además dos columnas residuales del proceso de codificación (Region_Nan y Gender_Nan), correspondientes a valores 'NaN' tratados como string durante la imputación, las cuales fueron eliminadas en el modelo refinado de la Parte 4.

Construcción del Modelo (Paso 3)

Los datos codificados fueron divididos en conjunto de entrenamiento (80%) y de prueba (20%) mediante train_test_split con random_state=42, garantizando reproducibilidad. Antes de la división, se eliminaron filas con valores infinitos o nulos residuales para asegurar la estabilidad numérica del ajuste.

Se construyeron dos modelos de regresión lineal con todas las variables disponibles:

- **Regresión OLS con statsmodels**: permite obtener el resumen estadístico completo del modelo, incluyendo coeficientes, errores estándar, estadísticos t y p-valores para cada predictor, así como métricas globales como el R^2 y el R^2 ajustado. Se añadió una constante mediante sm.add_constant() antes del ajuste.
- **Regresión lineal con scikit-learn**: orientada principalmente a la predicción, permite calcular métricas de desempeño (MAE, MAPE, RMSE, R^2) tanto en entrenamiento como en prueba de manera directa.

Ambos modelos utilizaron exactamente las mismas variables y división de datos, produciendo predicciones idénticas, lo que verificó la consistencia entre implementaciones.

Evaluación del Modelo (Paso 4)

Se definió una función de evaluación que calcula de forma consistente las cinco métricas requeridas: MAE, MAPE, RMSE, R^2 y R^2 ajustado, tanto para entrenamiento como para prueba en ambos modelos.

Los resultados del modelo completo arrojaron un R^2 de 0,507 en entrenamiento y 0,618 en prueba, con un MAE de $6.545 USD y MAPE de 9,02% en el conjunto de prueba. La diferencia entre ambos conjuntos no indica sobreajuste, sino que refleja la variabilidad propia de la partición aleatoria. El summary OLS reportó además un condition number de $1{,}9\times10^3$, señal consistente con la multicolinealidad diagnosticada posteriormente mediante el VIF.

4.Análisis y Refinamiento del Modelo

Interpretación de P-valores (Paso 1)

A partir del resumen OLS del modelo completo, se ordenaron las variables según su p-valor para identificar aquellas estadísticamente insignificantes. Se detectaron tres variables con $p > 0{,}05$: Gender_Nan ($p = 0{,}911$), Region_Nan ($p = 0{,}715$) y Region_West ($p = 0{,}142$).

Las dos primeras corresponden a categorías residuales generadas durante el proceso de codificación, producto de valores 'NaN' tratados como string en la imputación. Al no tener interpretación de negocio, fueron eliminadas del modelo refinado. Region_West, en cambio, fue conservada: su insignificancia estadística puede deberse a que la variabilidad salarial de esa región ya está parcialmente capturada por otras variables del modelo, y su exclusión podría sesgar las predicciones para empleados ubicados en esa zona geográfica.

La eliminación de las columnas NaN no produjo cambios relevantes en las métricas: el modelo refinado mantuvo $R^2 = 0{,}618$ en prueba y MAE de $6.545 USD, confirmando que esas variables no aportaban información predictiva real.

Análisis de Multicolinealidad — VIF (Paso 2)

Se calculó el Factor de Inflación de Varianza (VIF) para todas las variables del modelo refinado. Los resultados confirmaron la multicolinealidad anticipada en el Paso 1 de la Parte 3:

- **Age**: VIF = 15,58 — multicolinealidad severa (> 10)
- **Job_Level**: VIF = 9,85 — multicolinealidad moderada-alta
- **Years_Experience**: VIF = 9,71 — multicolinealidad moderada-alta
- **Resto de variables**: VIF < 5 — sin problemas relevantes

El VIF elevado de Age refleja su correlación de 0,72 con Years_Experience observada en el heatmap. A pesar de esto, se decidió conservar ambas variables en el modelo, dado que capturan dimensiones conceptualmente distintas: Age representa la edad biológica del empleado, mientras que Years_Experience mide la trayectoria profesional acumulada. Un empleado puede tener

mucha edad y poca experiencia, o viceversa. Se reconoce como limitación que los errores estándar de estos coeficientes están inflados, lo que dificulta su interpretación individual pero no invalida el poder predictivo global del modelo.

Verificación de Supuestos de Regresión (Paso 3)

Se verificaron los dos supuestos principales de la regresión lineal sobre el modelo refinado:

Normalidad de residuos: el histograma de residuos muestra una distribución muy concentrada en torno a cero con cola derecha extendida, y el gráfico Q-Q evidencia desviación significativa en ambas colas. Se concluye que los residuos no siguen una distribución normal estricta. Esta desviación es esperable en datos salariales reales, donde la presencia de sueldos muy altos genera asimetría estructural. Para el objetivo predictivo del proyecto esta limitación es aceptable, aunque implica que los intervalos de confianza de los coeficientes deben interpretarse con cautela.

Homocedasticidad: la prueba de Breusch-Pagan arrojó un estadístico LM = 11,33 con p-valor = 0,656, por lo que no se rechaza H_0. La varianza de los errores es razonablemente constante a lo largo de los valores predichos, lo que constituye una condición favorable para la validez de las inferencias del modelo.

COLAB: https://colab.research.google.com/drive/19ya-OySpuI8g8LCIf4RarscnM509hsUQ?usp=sharing